

Ασαφή Συστήματα

Εργασία 4 - Σειρά 11

Δημανίδης Ιωάννης - 8358

Μοντέλα Singleton

Εκπαίδευση με back-propagation

Δημιουργούμε τα σύνολα D_{trn} , D_{val} , D_{chk} τα οποία είναι της μορφής


$$\begin{bmatrix} x(t-12) & x(t-6) & x(t) & x(t+6) \end{bmatrix}$$

παιρνοντας τις τιμές της χρονοσειράς από το δοσμένο dataset. Αρχικοποιούμε το μηδενικής τάξης TSK με τη χρήση του διαμερισμού πλέγματος, και δίνουμε τυχαίες τιμές στα βάρη του τμήματος συμπεράσματος.

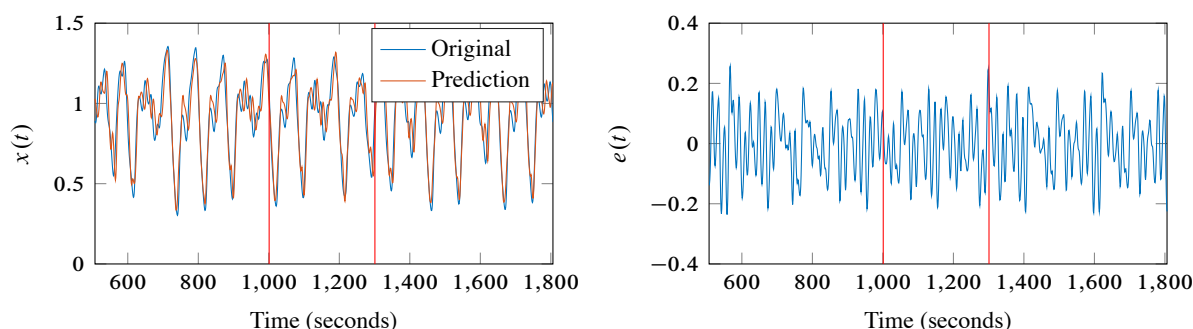
Έπειτα, εκπαιδεύουμε το μοντέλο μας με τη χρήση του αλγορίθμου back-propagation για 1000 epochs χρησιμοποιώντας το D_{trn} και το D_{val} και θεωρούμε το βέλτιστο μοντέλο αυτό το οποίο προσφέρει το μικρότερο RMSE στα στοιχεία του συνόλου αξιολόγησης. Στο σχήμα 2 παρουσιάζονται οι προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές, καθώς και το μεταξύ τους σφάλμα. Οι κόκκινες γραμμές διαχωρίζουν τα 3 σύνολα D_{trn} , D_{val} , D_{chk} μεταξύ τους. Παρατηρούμε λοιπόν πως ακολουθούμε αρκετά καλά την χρονοσειρά με το σφάλμα να κυμαίνεται σε σχετικά αποδεκτά επίπεδα, όπως φαίνεται και από τις μετρικές που παρουσιάζονται στον πίνακα 1. Επίσης, παρατηρώντας τους δείκτες σφάλματος, βλέπει κανείς ότι ο κάθε δείκτης είναι σχεδόν ίδιος και για τα 3 σύνολα, πράγμα που σημαίνει ότι δεν έχουμε υπερεκπαίδευση. Αυτό επαληθεύεται και από τις καμπύλες εκμάθησης που παρουσιάζονται στο σχήμα 1, όπου σχεδόν ταυτίζονται.

	RMSE	NMSE	NDEI
D_{trn}	0.10138	0.16465	0.40577
D_{val}	0.09679	0.15820	0.39774
D_{chk}	0.09909	0.14911	0.38615


Πίνακας 1: Δείκτες σφαλμάτων για το μοντέλο singleton TSK (BP)



Σχήμα 1: Καμπύλες εκμάθησης για το μοντέλο singleton TSK (BP)



Σχήμα 2: Προβλέψεις μοντέλου singleton TSK (BP) σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς και το μεταξύ τους σφάλμα



Σχήμα 3: Σύνολα εισόδου για το μοντέλο singleton TSK (BP)

Στο σχήμα 6 παρουσιάζονται τα τελικά σύνολα εισόδου που προέκυψαν από την εκπαίδευση του μοντέλου μας με τη χρήση back-propagation. Να σημειωθεί ότι ορίζουμε ως την είσοδο x_1 το $x(t - 12)$, ως την είσοδο x_2 το $x(t - 6)$, ως την είσοδο x_3 το $x(t)$ και ως την έξοδο $y = \hat{x}(t + 6)$. Επιπλέον, στον πίνακα 2 παρουσιάζεται η βάση κανόνων που προέκυψε για το μοντέλο μας.

Rule	x_1	x_2	x_3	y	Value
R_1	A_1^1	A_2^1	A_3^1	w_1	0.7360
R_2	A_1^1	A_2^1	A_3^2	w_2	1.4084
R_3	A_1^1	A_2^2	A_3^1	w_3	-0.0741
R_4	A_1^1	A_2^2	A_3^2	w_4	1.8594
R_5	A_1^2	A_2^1	A_3^1	w_5	0.2140
R_6	A_1^2	A_2^1	A_3^2	w_6	0.3194
R_7	A_1^2	A_2^2	A_3^1	w_7	-0.1181
R_8	A_1^2	A_2^2	A_3^2	w_8	1.1641

Πίνακας 2: Ασαφής βάση κανόνων για το μοντέλο singleton TSK (BP)

Εκπαίδευση με υβριδικό αλγόριθμο

Δημιουργούμε τα σύνολα D_{trn} , D_{val} , D_{chk} τα οποία είναι της μορφής


$$\begin{bmatrix} x(t - 12) & x(t - 6) & x(t) & x(t + 6) \end{bmatrix}$$

παίρνοντας τις τιμές της χρονοσειράς από το δοσμένο dataset. Αρχικοποιούμε το μηδενικής τάξης TSK με τη χρήση του διαμερισμού πλέγματος, και δίνουμε τυχαίες τιμές στα βάρη του τμήματος συμπεράσματος.

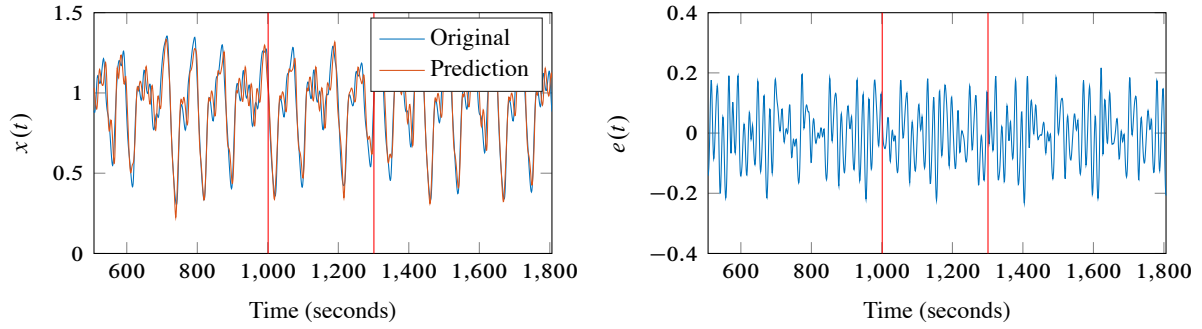
Έπειτα, εκπαιδεύουμε το μοντέλο μας με τη χρήση υβριδικού αλγορίθμου για 1000 epochs χρησιμοποιώντας το D_{trn} και το D_{val} και θεωρούμε το βέλτιστο μοντέλο αυτό το οποίο προσφέρει το μικρότερο RMSE στα στοιχεία του συνόλου αξιολόγησης. Στο σχήμα 5 παρουσιάζονται οι προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές, καθώς και το μεταξύ τους σφάλμα. Οι κόκκινες γραμμές

	RMSE	NMSE	NDEI
D_{trn}	0.09423	0.14226	0.37717
D_{val}	0.08833	0.13177	0.36299
D_{chk}	0.09095	0.12562	0.35443

Πίνακας 3: Δείκτες σφαλμάτων για το μοντέλο singleton TSK (Hybrid)



Σχήμα 4: Καμπύλες εκμάθησης για το μοντέλο singleton TSK (Hybrid)




Σχήμα 5: Προβλέψεις μοντέλου singleton TSK (Hybrid) σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς και το μεταξύ τους σφάλμα

διαχωρίζουν τα 3 σύνολα D_{trn} , D_{val} , D_{chk} μεταξύ τους. Παρατηρούμε λοιπόν πως ακολουθούμε αρκετά καλά την χρονοσειρά με το σφάλμα να κυμαίνεται σε σχετικά αποδεκτά επίπεδα, όπως φαίνεται και από τις μετρικές που παρουσιάζονται στον πίνακα 3. Επίσης, παρατηρώντας τους δείκτες σφάλματος, βλέπει κανείς ότι ο κάθε δείκτης είναι σχεδόν ίδιος και για τα 3 σύνολα, πράγμα που σημαίνει ότι δεν έχουμε υπερεκπαίδευση. Αυτό επαληθεύεται και από τις καμπύλες εκμάθησης που παρουσιάζονται στο σχήμα 4, όπου βρίσκονται αρκετά κοντά, με το σφάλμα αξιολόγησης μικρότερο από το σφάλμα εκμάθησης, πράγμα το οποίο είναι απλά περιστασιακό και δεν σημαίνει κάτι παραπάνω. Επιπλέον παρατηρούμε ότι οι καμπύλες σφάλματος ξεκινάνε αμέσως από πολύ χαμηλότερο αρχικό σφάλμα, πράγμα το οποίο συμβαίνει διότι για να βρούμε τα βάρη των συμπερασμάτων επιλύουμε την κανονική εξίσωση, οπότε έχοντας βρει τα βέλτιστα συμπεράσματα εκτελούμε BP για να τοποθετήσουμε βέλτιστα τα σύνολα εισόδου. Ποιοτικά, τα τελικά μας αποτελέσματά είναι παρόμοια με προηγούμενως με τη μόνη διαφορά ότι οι δείκτες σφάλματος είναι ελαφρώς μικρότεροι από ότι ήταν πριν.

Στο σχήμα 6 παρουσιάζονται τα τελικά σύνολα εισόδου που προέκυψαν από την εκπαίδευση του μοντέλου μας με τη χρήση υβριδικού αλγορίθμου. Να σημειωθεί ότι ορίζουμε ως την είσοδο x_1 το $x(t - 12)$, ως την είσοδο x_2 το $x(t - 6)$, ως την είσοδο x_3 το $x(t)$ και ως την έξοδο $y = \hat{x}(t + 6)$. Επιπλέον, στον πίνακα 4 παρουσιάζεται η βάση κανόνων που προέκυψε για το μοντέλο μας. Παρατηρούμε ότι ενώ τα σύνολα εισόδου ποιοτικά είναι παρόμοια με τα προηγούμενα, τα βάρη συμπερασμάτων είναι εντελώς διαφορετικά.

Rule	x_1	x_2	x_3	y	Value
R_1	A_1^1	A_2^1	A_3^1	w_1	2.5985
R_2	A_1^1	A_2^1	A_3^2	w_2	-2.4402
R_3	A_1^1	A_2^2	A_3^1	w_3	-0.4113
R_4	A_1^1	A_2^2	A_3^2	w_4	2.6936
R_5	A_1^2	A_2^1	A_3^1	w_5	-14.1754
R_6	A_1^2	A_2^1	A_3^2	w_6	32.2245
R_7	A_1^2	A_2^2	A_3^1	w_7	-0.0628
R_8	A_1^2	A_2^2	A_3^2	w_8	0.7743

Πίνακας 4: Ασαφής βάση κανόνων για το μοντέλο singleton TSK (Hybrid)



Σχήμα 6: Σύνολα εισόδου για το μοντέλο singleton TSK (Hybrid)

Μοντέλα TSK

Εκπαίδευση με back-propagation

Δημιουργούμε τα σύνολα D_{trn} , D_{val} , D_{chk} τα οποία είναι της μορφής

$$\begin{bmatrix} x(t-12) & x(t-6) & x(t) & x(t+6) \end{bmatrix}$$


παιρνοντας τις τιμές της χρονοσειράς από το δοσμένο dataset. Αρχικοποιούμε το πρώτης τάξης TSK με τη χρήση του διαμερισμού πλέγματος, και δίνουμε τυχαίες τιμές στα βάρη του τμήματος συμπεράσματος.

Έπειτα, εκπαιδεύουμε το μοντέλο μας με τη χρήση του αλγορίθμου back-propagation για 1000 epochs χρησιμοποιώντας το D_{trn} και το D_{val} και θεωρούμε το βέλτιστο μοντέλο αυτό το οποίο προσφέρει το μικρότερο RMSE στα στοιχεία του συνόλου αξιολόγησης. Στο σχήμα 8 παρουσιάζονται οι προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές, καθώς και το μεταξύ τους σφάλμα. Οι κόκκινες γραμμές διαχωρίζουν τα 3 σύνολα D_{trn} , D_{val} , D_{chk} μεταξύ τους. Παρατηρούμε λοιπόν πως ακολουθούμε αρκετά καλά την χρονοσειρά με το σφάλμα να κυμαίνεται σε σχετικά αποδεκτά επίπεδα, όπως φαίνεται και από τις μετρικές που παρουσιάζονται στον πίνακα 5. Επίσης, παρατηρώντας τους δείκτες σφάλματος, βλέπει κανείς ότι ο κάθε δείκτης είναι σχεδόν ίδιος και για τα 3 σύνολα, πράγμα που σημαίνει ότι δεν έχουμε υπερεκπαίδευση. Αυτό επαληθεύεται και από τις καμπύλες εκμάθησης που παρουσιάζονται στο σχήμα 7, όπου σχεδόν ταυτίζονται.

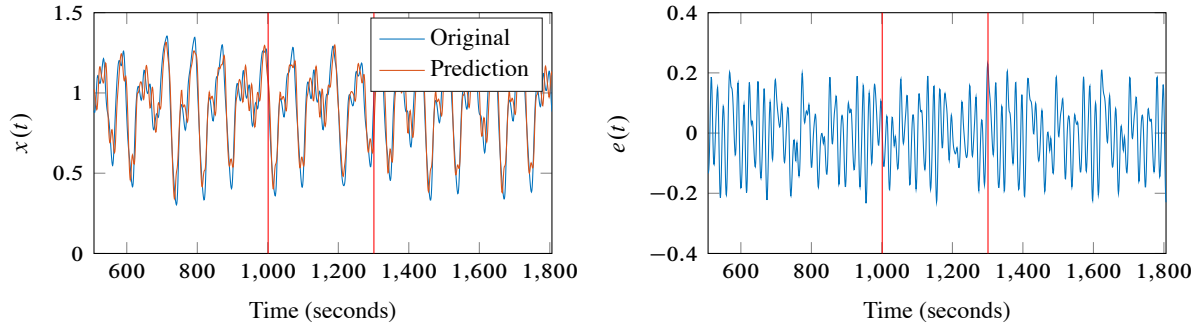
Στο σχήμα 9 παρουσιάζονται τα τελικά σύνολα εισόδου που προέκυψαν από την εκπαίδευση του μοντέλου μας με τη χρήση back-propagation. Να σημειωθεί ότι ορίζουμε ως την είσοδο x_1 το $x(t-12)$, ως την είσοδο x_2 το $x(t-6)$, ως την είσοδο x_3 το $x(t)$ και ως την έξοδο $y = \hat{x}(t+6)$.

	RMSE	NMSE	NDEI
D_{trn}	0.10138	0.16465	0.40577
D_{val}	0.09679	0.15820	0.39774
D_{chk}	0.09909	0.14911	0.38615

Πίνακας 5: Δείκτες σφαλμάτων για το μοντέλο first-order TSK (BP)



Σχήμα 7: Καμπύλες εκμάθησης για το μοντέλο first-order TSK (BP)



Σχήμα 8: Προβλέψεις μοντέλου first-order TSK (BP) σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς και το μεταξύ τους σφάλμα


Rule	x_1	x_2	x_3	y	$g_{i,3}$	$g_{i,2}$	$g_{i,1}$	$g_{i,0}$
R_1	A_1^1	A_2^1	A_3^1	w_1	0.3733	0.6889	-0.0168	0.2565
R_2	A_1^1	A_2^1	A_3^2	w_2	0.1502	0.1266	0.3493	0.4002
R_3	A_1^1	A_2^2	A_3^1	w_3	0.3397	0.4917	0.3824	0.6214
R_4	A_1^1	A_2^2	A_3^2	w_4	0.3806	0.0735	0.8657	0.1984
R_5	A_1^2	A_2^1	A_3^1	w_5	0.3162	0.4843	0.0866	0.0913
R_6	A_1^2	A_2^1	A_3^2	w_6	0.7054	0.9211	0.3634	0.5877
R_7	A_1^2	A_2^2	A_3^1	w_7	0.6594	0.7226	-0.0437	-0.1652
R_8	A_1^2	A_2^2	A_3^2	w_8	-0.1441	-0.2612	1.1968	-0.1784

Πίνακας 6: Ασαφής βάση κανόνων για το μοντέλο first-order TSK (BP)

Δεδομένου όμως ότι έχουμε μοντέλο TSK πρώτης τάξης, η έξοδος μας εκφράζεται ως γραμμικός συνδυασμός των εισόδων. Έτσι έχουμε:

$$w_i = g_{i,3}x_3 + g_{i,2}x_2 + g_{i,1}x_1 + g_{i,0}, i = 1, 2, \dots, 8$$

Στον πίνακα 6 παρουσιάζεται η βάση κανόνων που προέκυψε για το μοντέλο μας με όλες τις τιμές των συντελεστών συμπεράσματος.



Σχήμα 9: Σύνολα εισόδου για το μοντέλο first-order TSK (BP)

Εκπαίδευση με υβριδικό αλγόριθμο

Δημιουργούμε τα σύνολα D_{trn} , D_{val} , D_{chk} τα οποία είναι της μορφής

$$\begin{bmatrix} x(t-12) & x(t-6) & x(t) & x(t+6) \end{bmatrix}$$

παίρνοντας τις τιμές της χρονοσειράς από το δοσμένο dataset. Αρχικοποιούμε το πρώτης τάξης TSK με τη χρήση του διαμερισμού πλέγματος, και δίνουμε τυχαίες τιμές στα βάρη του τμήματος συμπεράσματος.

Έπειτα, εκπαιδεύουμε το μοντέλο μας με τη χρήση υβριδικού αλγορίθμου για 1000 epochs χρησιμοποιώντας το D_{trn} και το D_{val} και θεωρούμε το βέλτιστο μοντέλο αυτό το οποίο προσφέρει το μικρότερο RMSE στα στοιχεία του συνόλου αξιολόγησης. Στο σχήμα 11 παρουσιάζονται οι προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές, καθώς και το μεταξύ τους σφάλμα. Οι κόκκινες γραμμές διαχωρίζουν τα 3 σύνολα D_{trn} , D_{val} , D_{chk} μεταξύ τους. Παρατηρούμε λοιπόν πως ακολουθούμε αρκετά καλά την χρονοσειρά με το σφάλμα να κυμαίνεται σε σχετικά αποδεκτά επίπεδα, όπως φαίνεται και από τις μετρικές που παρουσιάζονται στον πίνακα 5. Επίσης, παρατηρώντας τους δείκτες σφάλματος, βλέπει κανείς ότι ο κάθε δείκτης είναι σχεδόν ίδιος και για τα 3 σύνολα, πράγμα που σημαίνει ότι δεν έχουμε υπερεκπαίδευση. Παρατηρούμε ότι καμπύλη αξιολόγησης βρίσκεται μονίμως πάνω από την καμπύλη εκμάθησης, αλλά ανήκουν στην ίδια τάξη μεγέθους, οπότε δεν τίθενται ζητήματα υπερεκπαίδευσης. Επιπλέον παρατηρούμε ότι οι καμπύλες σφάλματος ξεκινάνε αμέσως από πολύ χαμηλότερο αρχικό σφάλμα, πράγμα το οποίο συμβαίνει διότι για να βρούμε τα βάρη των συμπερασμάτων επιλύουμε την κανονική εξίσωση, οπότε έχοντας βρει τα βέλτιστα συμπεράσματα εκτελούμε BP για να τοποθετήσουμε βέλτιστα τα σύνολα εισόδου.


Στο σχήμα 12 παρουσιάζονται τα τελικά σύνολα εισόδου που προέκυψαν από την εκπαίδευση του μοντέλου μας με τη χρήση υβριδικού αλγορίθμου. Να σημειωθεί ότι ορίζουμε ως την είσοδο x_1 το $x(t-12)$, ως την είσοδο x_2 το $x(t-6)$, ως την είσοδο x_3 το $x(t)$ και ως την έξοδο $y = \hat{x}(t+6)$. Δεδομένου όμως ότι έχουμε μοντέλο TSK πρώτης τάξης, η έξοδος μας εκφράζεται ως γραμμικός συνδυασμός των εισόδων. Έτσι έχουμε:

$$w_i = g_{i,3}x_3 + g_{i,2}x_2 + g_{i,1}x_1 + g_{i,0}, i = 1, 2, \dots, 8$$


Στον πίνακα 8 παρουσιάζεται η βάση κανόνων που προέκυψε για το μοντέλο μας με όλες τις τιμές των συντελεστών συμπεράσματος.

	RMSE	NMSE	NDEI
D_{trn}	0.08247	0.10896	0.33009
D_{val}	0.07982	0.10758	0.32800
D_{chk}	0.07945	0.09586	0.30961

Πίνακας 7: Δείκτες σφαλμάτων για το μοντέλο first-order TSK (Hybrid)




Σχήμα 10: Καμπύλες εκμάθησης για το μοντέλο first-order TSK (Hybrid)



Σχήμα 11: Προβλέψεις μοντέλου first-order TSK (Hybrid) σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς και το μεταξύ τους σφάλμα

Rule	x_1	x_2	x_3	y	$g_{i,3}$	$g_{i,2}$	$g_{i,1}$	$g_{i,0}$
R_1	A_1^1	A_2^1	A_3^1	w_1	-0.4076	2.1974	0.8368	0.3666
R_2	A_1^1	A_2^1	A_3^2	w_2	1.9465	-4.4620	12.2254	-9.6454
R_3	A_1^1	A_2^2	A_3^1	w_3	2.5440	-23.9720	24.7996	1.8809
R_4	A_1^1	A_2^2	A_3^2	w_4	-2.1019	5.5147	1.2799	-5.7762
R_5	A_1^2	A_2^1	A_3^1	w_5	0.8252	1.3847	-1.0601	-1.5502
R_6	A_1^2	A_2^1	A_3^2	w_6	-4.5704	3.2347	-5.7864	8.5256
R_7	A_1^2	A_2^2	A_3^1	w_7	-2.5098	2.7766	-0.3148	1.2444
R_8	A_1^2	A_2^2	A_3^2	w_8	-0.5975	-2.0537	1.8488	2.1737

Πίνακας 8: Ασαφής βάση κανόνων για το μοντέλο first-order TSK (Hybrid)



Σχήμα 12: Σύνολα εισόδου για το μοντέλο first-order TSK (Hybrid)

Πρόβλεψη πολλαπλών βημάτων

Δημιουργούμε τα σύνολα D_{trn} , D_{val} , D_{chk} τα οποία είναι της μορφής

$$\begin{bmatrix} x(t-12) & x(t-6) & x(t) & x(t+6) \end{bmatrix}$$

παίρνοντας τις τιμές της χρονοσειράς από το δοσμένο dataset. Αρχικοποιούμε το πρώτης τάξης TSK με τη χρήση του διαμερισμού πλέγματος με τέσσερα ασαφή σύνολα στην είσοδο αντί για δύο, και δίνουμε τυχαίες τιμές στα βάρη του τμήματος συμπεράσματος.


Εκπαιδεύουμε εκπαιδεύουμε το μοντέλο μας με τη χρήση υβριδικού αλγορίθμου για 1000 epochs χρησιμοποιώντας το D_{trn} και το D_{val} και θεωρούμε το βέλτιστο μοντέλο αυτό το οποίο προσφέρει το μικρότερο RMSE στα στοιχεία του συνόλου αξιολόγησης. Στο σχήμα 13 φαίνονται οι καμπύλες εκμάθησης και αξιολόγησης της διαδικασίας εκπαίδευσης, και παρατηρούμε ότι καμπύλη αξιολόγησης βρίσκεται μονίμως πάνω από την καμπύλη εκμάθησης, αλλά ανήκουν στην ίδια τάξη μεγέθους, οπότε δεν τίθενται ζητήματα υπερεκπαίδευσης. Μέχρι στιγμής έχουμε ακολουθήσει την ίδια διαδικασία με προηγούμενως, οπότε και το τελικό μοντέλο που προκύπτει είναι το ίδιο, με τις τελικές των παραμέτρων να παρουσιάζονται στο σχήμα 12 και στον πίνακα 8. Έπειτα αναδράται η έξοδος στην είσοδο, παράγοντας σύνολα προβλέψεων της μορφής

$$\begin{aligned} \{x(t-12), x(t-6), x(t)\} &\rightarrow \hat{x}(t+6) \\ \{x(t-6), x(t), \hat{x}(t+6)\} &\rightarrow \hat{x}(t+12) \\ &\vdots \\ \{\hat{x}(t+84), \hat{x}(t+88), \hat{x}(t+92)\} &\rightarrow \hat{x}(t+96) \end{aligned}$$

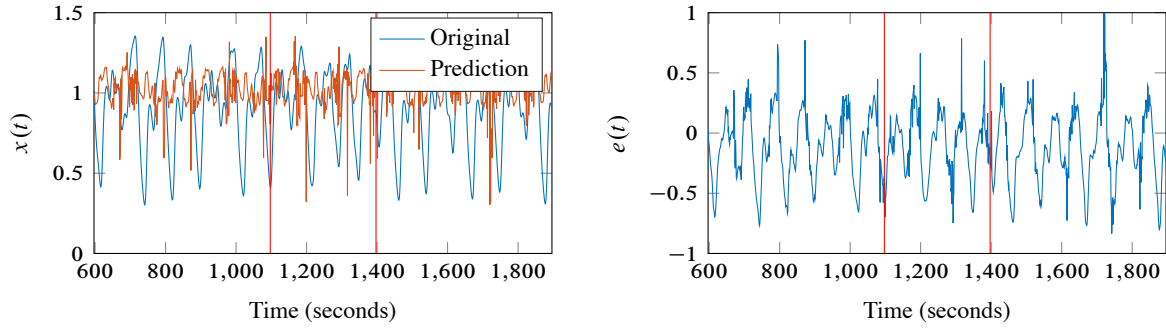
Στο σχήμα 14 παρουσιάζονται οι προβλέψεις πολλαπλών βημάτων του μοντέλου που εκπαιδεύσαμε σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς. Παρατηρεί κανείς ότι πλέον οι προβλέψεις μας έχουν χάσει την ακρίβεια τους, προβλέποντας τις πραγματικές τιμές της χρονοσειράς με πολύ μέτρια επιτυχία, γεγονός που επαληθεύεται και από τον πίνακα 9, όπου παρουσιάζονται οι μετρικές σφάλματος. Οι δείκτες σφάλματος έχουν σαφώς αυξημένες τιμές, αλλά ο κάθε δείκτης και για τα τρία σύνολα κυμαίνεται στα ίδια επίπεδα, οπότε δεν έχουμε υπερεκπαίδευση, πράγμα αναμενόμενο άλλωστε καθώς έχουμε το ίδιο μοντέλο που παρουσιάστηκε στο προηγούμενο ερώτημα. Παρατηρούμε ότι οι προβλέψεις μας επικεντρώνονται γύρω από

	RMSE	NMSE	NDEI
D_{trn}	0.30579	1.49810	1.2240
D_{val}	0.27387	1.26670	1.1255
D_{chk}	0.32353	1.58970	1.2608

Πίνακας 9: Δείκτες σφαλμάτων για πρόβλεψη πολλαπλών βημάτων με μοντέλο first-order TSK (Hybrid)



Σχήμα 13: Καμπύλες εκμάθησης το μοντέλο first-order TSK (Hybrid) που χρησιμοποιήθηκε για πρόβλεψη πολλαπλών βημάτων



Σχήμα 14: Προβλέψεις πολλαπλών βημάτων μοντέλου first-order TSK (Hybrid) σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς και το μεταξύ τους σφάλμα

τη μέση τιμή της χρονοσειράς με κάποια spikes να δημιουργούνται όταν συσσωρεύεται μεγάλο σφάλμα. Μάλιστα χρειάστηκε σε κάθε αναδρομικό βήμα να περιορίζουμε τις προβλέψεις μας στην περιοχή τιμών της χρονοσειράς, καθώς χωρίς saturation τα spikes αυτά, λόγω της συσσώρευσης του σφάλματος, έπαιρναν πολύ μεγάλες τιμές οδηγώντας έτσι το σύστημα μας σε ασταθείς καταστάσεις.

Υπερεκπαίδευση

Δημιουργούμε τα σύνολα D_{trn} , D_{val} , D_{chk} τα οποία είναι της μορφής


$$\begin{bmatrix} x(t-12) & x(t-6) & x(t) & x(t+6) \end{bmatrix}$$

παίρνοντας τις τιμές της χρονοσειράς από το δοσμένο dataset. Αρχικοποιούμε το πρώτης τάξης TSK με τη χρήση του διαμερισμού πλέγματος με τέσσερα ασαφή σύνολα στην είσοδο αντί για δύο, και δίνουμε τυχαίες τιμές στα βάρη του τμήματος συμπεράσματος.

Έπειτα, εκπαιδεύουμε το μοντέλο μας με τη χρήση υβριδικού αλγορίθμου για 1000 epochs χρησιμοποιώντας το D_{trn} και το D_{val} και θεωρούμε το βέλτιστο μοντέλο αυτό το οποίο προσφέρει το μικρότερο RMSE στα στοιχεία του συνόλου αξιολόγησης. Στο σχήμα 16 παρουσιάζονται οι προβλέψεις του μοντέλου σε σύγκριση με τις πραγματικές τιμές, καθώς και το μεταξύ τους σφάλμα. Οι κόκκινες γραμμές διαχωρίζουν τα 3 σύνολα D_{trn} , D_{val} , D_{chk} μεταξύ τους. Παρατηρούμε λοιπόν ότι η αυξημένη πολυπλοκότητα έχει άμεσο αντίκτυπο στην ποιότητα των προβλέψεων καθώς βλέπει κανείς ότι στο σύνολο εκπαίδευσης το σφάλμα

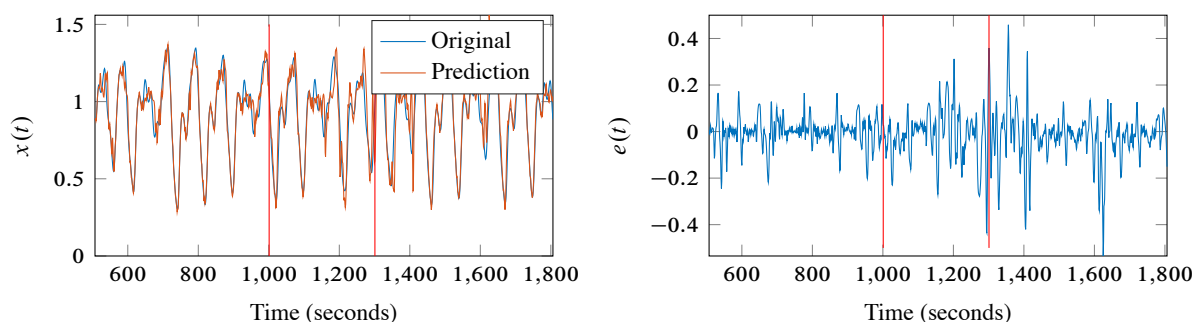
	RMSE	NMSE	NDEI
D_{trn}	0.06230	0.06217	0.24934
D_{val}	0.11716	0.23183	0.48149
D_{chk}	0.10988	0.18337	0.42822

Πίνακας 10: Δείκτες σφαλμάτων για το υπερεκπαιδευμένο μοντέλο first-order TSK (Hybrid)



Σχήμα 15: Καμπύλες εκμάθησης για το υπερεκπαιδευμένο μοντέλο first-order TSK (Hybrid)

είναι πολύ μικρότερο από ότι είναι στα άλλα δύο σύνολα. Επιπλέον, οι δείκτες σφάλματος, που φαίνονται στον πίνακα 10, για το σύνολο εκπαίδευσης είναι μεν οι πιο χαμηλοί από κάθε άλλη μοντελοποίηση, αλλά στα υπόλοιπα σύνολα είναι μεγαλύτεροι. Ακόμη, στο σχήμα 15 φαίνονται οι καμπύλες εκμάθησης και αξιολόγησης της διαδικασίας εκπαίδευσης, και παρατηρούμε ότι καμπύλη αξιολόγησης βρίσκεται μονιμώς πάνω από την καμπύλη εκμάθησης. Όλα αυτά μας δείχνουν πως το μοντέλο μας είναι υπερεκπαιδευμένο λόγω της υψηλής του πολυπλοκότητας.




Σχήμα 16: Προβλέψεις υπερεκπαιδευμένου μοντέλου first-order TSK (Hybrid) σε σύγκριση με τις πραγματικές τιμές της χρονοσειράς και το μεταξύ τους σφάλμα

Στο σχήμα 17 παρουσιάζονται τα τελικά σύνολα εισόδου που προέκυψαν από την εκπαίδευση του μοντέλου μας με τη χρήση υβριδικού αλγορίθμου. Να σημειωθεί ότι ορίζουμε ως την είσοδο x_1 το $x(t-12)$, ως την είσοδο x_2 το $x(t-6)$, ως την είσοδο x_3 το $x(t)$ και ως την έξοδο $y = \hat{x}(t+6)$. Δεδομένου όμως ότι έχουμε μοντέλο TSK πρώτης τάξης, η έξοδος μας εκφράζεται ως γραμμικός συνδυασμός των εισόδων. Έτσι έχουμε:

$$w_i = g_{i,3}x_3 + g_{i,2}x_2 + g_{i,1}x_1 + g_{i,0}, i = 1, 2, \dots, 64$$

Οι παράμετροι $g_{i,j}$ δεν παρουσιάζονται αναλυτικά εδώ, καθώς μιλάμε για 64 κανόνες από 4 παραμέτρους ο κάθε ένας και δεν θα είχε νόημα. Το πλήρες το μοντέλο με όλες του τις παραμέτρους μπορεί να βρεθεί στα αρχεία κώδικα.



Σχήμα 17: Σύνολα εισόδου για το υπερεκπαιδευμένο μοντέλο first-order TSK (Hybrid)